

Universidade Federal de São Carlos

Programa de Pós-graduação em Ciências Ambientais

Disciplina: Introdução a Ciência de Dados Ambientais

Docentes: Prof.^a Dr^a Sílvia C. Jesus

Discentes: Anita di Vito

Emmanuélly Maria de Souza Fernandes. RA:582700

1. DEFINIÇÃO DO PROBLEMA

A população humana na Terra tem apresentado um crescimento constante. Em 2014, eram cerca de 7,3 bilhões de pessoas, e as estimativas atuais apontam para 8,2 bilhões. Esse aumento indica que um número maior de pessoas precisa acessar recursos essenciais para a sobrevivência, como água, terra e minerais. Nesse contexto, mapear e monitorar esses recursos de forma rápida e precisa tornar-se uma ferramenta crucial para a manutenção da vida humana (Metternicht; Teece, 2023).

Uma das principais tecnologias utilizadas para esse fim é o sensoriamento remoto, que permite a obtenção de imagens orbitais da superfície terrestre. Essas imagens possibilitam a realização de levantamentos temáticos diversos, incluindo estudos sobre ocupação e uso do solo, além do monitoramento de fenômenos dinâmicos que ocorrem na Terra (Kalaf et al., 2013). Por meio dessas imagens, é possível identificar feições específicas no território e elaborar mapas compostos por polígonos, cujos atributos podem abranger temas como vegetação, recursos hídricos, cobertura do solo e uso da terra (Novo; Ponzoni, 2008).

As informações obtidas por meio do sensoriamento remoto são fundamentais para a tomada de decisões mais assertivas e concretas. Por exemplo, podem ser empregadas no monitoramento de áreas de conservação ambiental e no acompanhamento de lavouras em imóveis rurais (Rosa, 2005). Em ambientes naturais, essas imagens permitem avaliar a extensão, o estado de conservação e a dinâmica das áreas estudadas em diferentes escalas, sejam elas locais ou globais (Boyde; Danson, 2005).

Para além da avaliação de impactos decorrentes de mudanças ambientais, é essencial quantificá-los. Nesse contexto, índices de vegetação, como o NDVI (Índice de Vegetação por Diferença Normalizada), fornecem informações quantitativas sobre a produtividade da vegetação, utilizando dados espectrais extraídos de imagens de satélite

(Vorovench, 2011). O NDVI mede a refletância da vegetação em bandas do vermelho e do infravermelho próximo, sendo influenciado pela densidade da cobertura vegetal e pelo conteúdo de clorofila nas folhas (Vorovench, 2011). Em outras palavras, o NDVI permite analisar a vegetação, identificando atividades sazonais, como mudanças ao longo das estações, períodos de senescência e a distribuição da vegetação em uma área específica (Gamarra et al., 2016).

O município de Pirassununga possui entre 10% e 15% de sua superfície coberta por vegetação natural, em uma área total de 72.634 hectares (ha), dos quais 10.780 ha são de vegetação nativa (Queiroz, 2024). Os fragmentos florestais da Guarnição de Aeronáutica de Pirassununga correspondem a 30,8% do território militar e representam 18,6% da vegetação nativa do município (Fernandes; Sebastiani; Sais, 2022; Queiroz, 2024). Assim, considerando a relevância da Guarnição da Aeronáutica de Pirassununga na conservação da biodiversidade local, em um cenário de rápida degradação ambiental no estado de São Paulo, este trabalho tem como objetivo mapear e analisar, por meio de geotecnologias, os fragmentos florestais presentes nessa área.

2. COLETA DE DADOS

1. Acessando o site Copernicus e efetuando login

1.1. Acesse o site: Abrimos o navegador e entramos no site do Copernicus Browser

1.2. Criação de uma conta

- Clicamos em **Sign Up** no canto superior direito.
- Preenchemos o formulário de cadastro com informações pessoais (nome, e-mail e senha).
- Verificamos e-mail para confirmar o registro.

1.3. Login

- Clicamos em **Sign In** no canto superior direito.
- Inserimos e-mail e senha cadastrados para acessar a plataforma.

2. Configuração dos parâmetros de busca das imagens de satélite Sentinel 2

2.1. Definição do período de análise

- No painel de filtros no lado esquerdo da tela.
- Na opção de **Datas**, no ícone do calendário, selecionamos o intervalo desejado:

- **Verão:** De 01/03/2023 a 31/05/2023.
- **Inverno:** De 01/09/2023 a 30/11/2023.

2.2. Seleção da área de interesse

- Utilizamos o mapa interativo para navegar até a região de estudo. No canto direito preenchemos o campo “Ir para o local”, digitamos Pirassununga e localizamos a Guarnição da Aeronáutica de Pirassununga.
- Clicamos e arrastar o retângulo de seleção para delimitar a área desejada.

2.3. Ajuste do filtro de cobertura de nuvens

- No menu lateral, localizamos a opção **Cloud Coverage**.
- Deslizamos o controle para limitar a cobertura de nuvens em até **20%**.

2.4. Escolhendo a imagem Sentinel-2

- Selecionamos o produto Sentinel-2, que é ideal para análise de NDVI.

3. Busca e seleção das imagens

3.1.Executando a busca

- Na aba “Procurar”, uma vez determinada as datas da busca, clicamos no botão de pesquisa para listar as imagens que atendem aos parâmetros configurados.

3.2. Analisando os resultados

- Verificamos as imagens disponíveis para as datas especificadas:
 - **Verão:** 24/04/2023.
 - **Inverno:** 11/09/2023.
- E nos certificamos de que a cobertura de nuvens é inferior a 20%

3.3. Fazendo o download

- Clicamos na imagem desejada para abrir os detalhes.
- Escolhemos a opção de download e selecionamos o formato apropriado (ex.: arquivos compactados com bandas espectrais).

3. LIMPEZA DE DADOS

Neste tópico descreve-se a transformação necessária para que os dados estejam prontos para análise. Dessa forma, com base no download das imagens Sentinel-2 de 24/04/2023 e 11/09/2023, realizou-se a etapa de limpeza de dados.

3.1. Descompactando o arquivo Zipado

- Com o WinRAR, um software de descompactação, extraímos os arquivos para uma pasta organizada, mantendo a estrutura original fornecida pelo Copernicus.

3.2. Abrindo e preparando os dados no QGIS

3.2.A - Abrir as bandas necessárias no QGIS

1. Abra o **QGIS 3.34 Prizren**.
2. No menu principal, acesse **Camada > Adicionar Camada > Adicionar Camada Raster**.
3. Navegue até a pasta contendo as bandas descompactadas:
 - **Caminho:** Granule > L2A_T22KHA_A042935_20230911T132237 > IMG_DATA_R10m.
4. Seleccionamos as bandas B04 e B08:
 - Seguramos **CTRL** e clique nas bandas B04 e B08 para seleccioná-las simultaneamente.
5. Clicamos em **Adicionar** e depois em **Fechar**.

3.2.B - Construindo uma imagem raster virtual

1. No menu principal, acessamos **Raster > Miscelânea > Construir Raster Virtual (VRT)**.
2. Na janela que se abriu:
 - Seleccionamos todas as camadas raster abertas (B04 e B08).
 - Nos certificamos de que as opções padrão estão marcadas para combinar os arquivos.
3. Feito isso, clicamos em **OK** para gerar o raster virtual, conforme Figura 1.

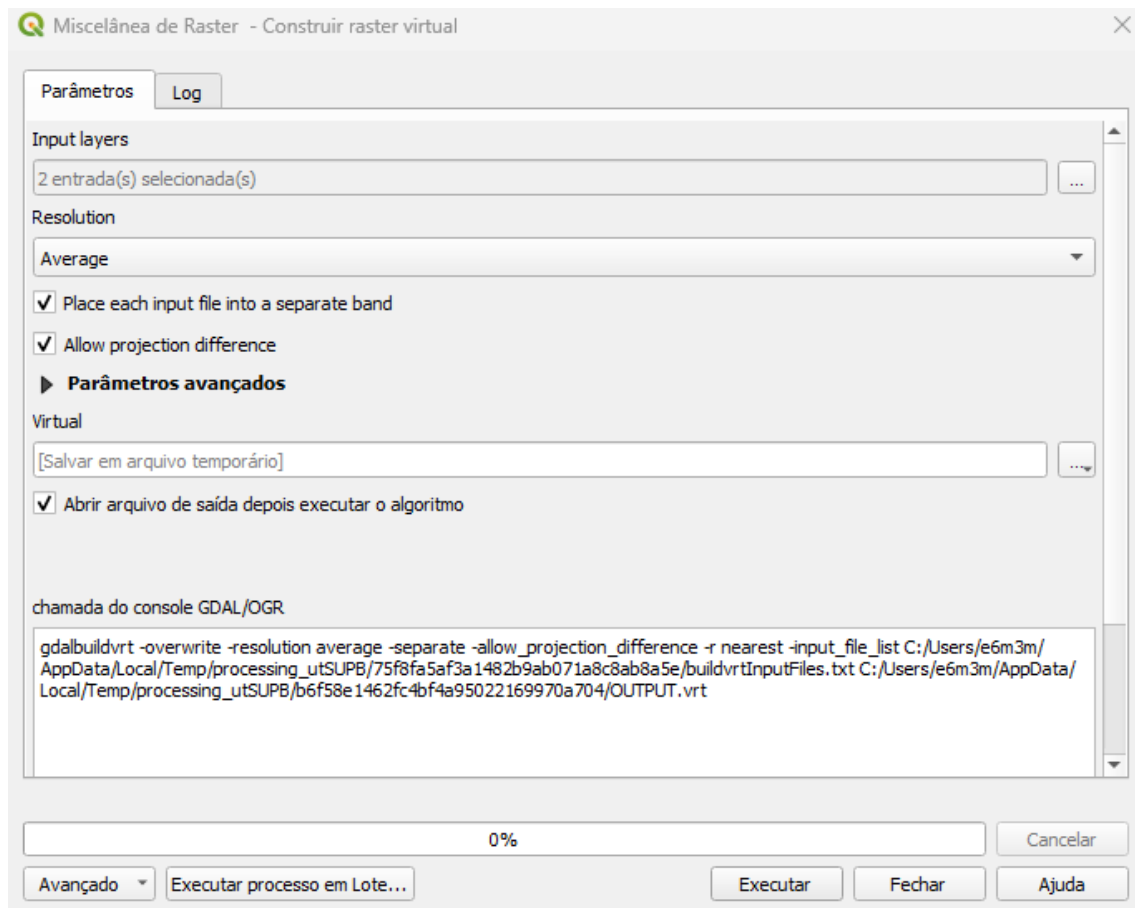


Figura 1 - Janela exibindo as configurações e as opções selecionadas para gerar a imagem raster. Fonte; As autoras

4. Salvamos os arquivos gerados, em um local acessível para futuras operações no Google Earth Engine.

Ao concluir essas etapas, obtivemos duas imagens raster (.GeoTIFF) prontas para serem utilizadas posteriormente em processos de análise no Google Earth Engine. Essas transformações asseguram que os dados estejam organizados e prontos para a próxima etapa de cálculo do NDVI. Tanto o arquivo contendo o algoritmo processado pelo QGIS, denominado rastervirtual.txt, quanto as imagens Verão_2023 e Inverno_2023 encontram-se no diretório do GitHub.

3.2.C – Exportando as imagens raster no QGIS

Para exportar as imagens raster no formato .GeoTIFF para utilizar posteriormente no Google Engine:

- Clicamos com o botão direito na camada raster desejada.

- Selecionamos "Exportar" > "Salvar como...".
- Escolhemos o formato GeoTIFF e definimos o nome e o local para salvar.
- Clicamos em "OK" para concluir a exportação.

4. ANÁLISE DE DADOS

A análise exploratória realizada neste trabalho tem continuidade em uma abordagem iniciada no Trabalho de Conclusão de Curso (TCC) de uma das discentes. No TCC, foram utilizadas imagens do satélite Landsat 8, sensor OLI, obtidas gratuitamente no site United States Geological Survey (USGS). Essas imagens, com resolução espacial de 30 metros, foram submetidas a um processamento digital que permitiu a obtenção do índice de vegetação NDVI (Normalized Difference Vegetation Index). As cenas analisadas correspondiam ao ponto e órbita 220/75, abrangendo dois períodos do ano de 2018: 14 de março, representando o verão, e 31 de agosto, representando o inverno. Para o cálculo do NDVI, foram utilizadas as bandas 4 (0,65 μm a 0,67 μm) e 5 (0,85 μm a 0,88 μm) das imagens.

Na presente análise, a metodologia foi refinada com o uso de imagens do satélite Sentinel-2, obtidas gratuitamente por meio da plataforma Copernicus. As imagens utilizadas possuem maior resolução espacial, de 10 metros, permitindo uma análise mais detalhada das áreas de estudo. As cenas analisadas foram capturadas em 24 de abril e 11 de setembro de 2023, correspondendo aos períodos de verão e final do inverno, respectivamente. Assim como no TCC, foi calculado o NDVI, desta vez utilizando as bandas 4 (665 nm) e 8 (842 nm) do Sentinel-2.

A comparação entre as duas abordagens, realizada a partir das diferentes resoluções espaciais dos satélites Landsat 8 e Sentinel-2, possibilita observar a evolução dos métodos de análise.

5. RESULTADOS

Com base nas classes utilizadas para a tipificação da vegetação, foram identificadas as seguintes formações vegetais, conforme detalhado na Figura 2.

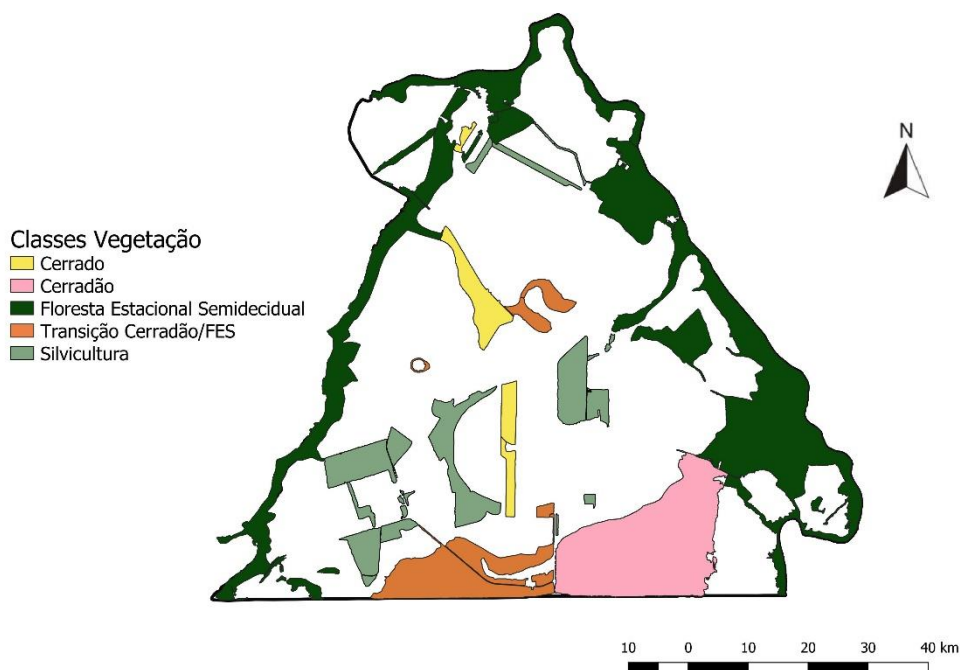


Figura 2. Fitofisionomias presentes na Guarnição da Aeronáutica de Pirassununga (SP).

O estudo analisou os índices de NDVI (Normalized Difference Vegetation Index) em diferentes fisionomias vegetais durante as estações do verão e inverno, destacando padrões específicos para cada tipo de cobertura. Na Floresta Estacional Semidecidual, os valores médios de NDVI variaram de 0,741 a 0,894 no verão e de 0,564 a 0,765 no inverno (Figura 3), com desvios padrão entre 0,023 e 0,130. Para o Cerrado, os valores médios oscilaram de 0,676 a 0,869 no verão e de 0,466 a 0,776 no inverno (Figura 3), com desvios padrão entre 0,034 e 0,109. Essas variações refletem diferenças na complexidade estrutural e na fitomassa, com a Floresta Estacional Semidecidual apresentando maior densidade e intrincamento, seguida pelo Cerradão.

Os valores de NDVI, que variam entre -1 e +1, indicam a densidade da vegetação, sendo mais próximos de +1 associados a maior atividade fotossintética. Conforme estudos anteriores, áreas vegetadas geralmente apresentam NDVI entre 0,1 e 0,8, dependendo de fatores como arquitetura das plantas, densidade e umidade do ambiente. Durante o inverno, observa-se uma redução no NDVI devido à perda de folhas, característica da deciduidade estacional, influenciada pelos fatores climáticos locais e históricos.

A análise temporal mostrou que os padrões de NDVI acompanham a variação pluviométrica entre as estações, com dados obtidos em 2018 pela Estação Meteorológica de Pirassununga. A persistência de altos índices de NDVI em algumas áreas do Cerrado

durante o período seco pode ser explicada pela adaptação das espécies, como folhas coriáceas e cascas grossas, que minimizam a perda de água.

Por fim, áreas destinadas à silvicultura normalmente apresentam NDVI entre 0,2 e 0,5 devido à redução da vegetação. No entanto, os dados revelaram valores entre 0,704 e 0,882 no verão e entre 0,494 e 0,791 no inverno, com desvios padrão de 0,024 a 0,138. Essa discrepância pode ser atribuída à regeneração natural dessas áreas, com o surgimento de espécies pioneiras.

2018

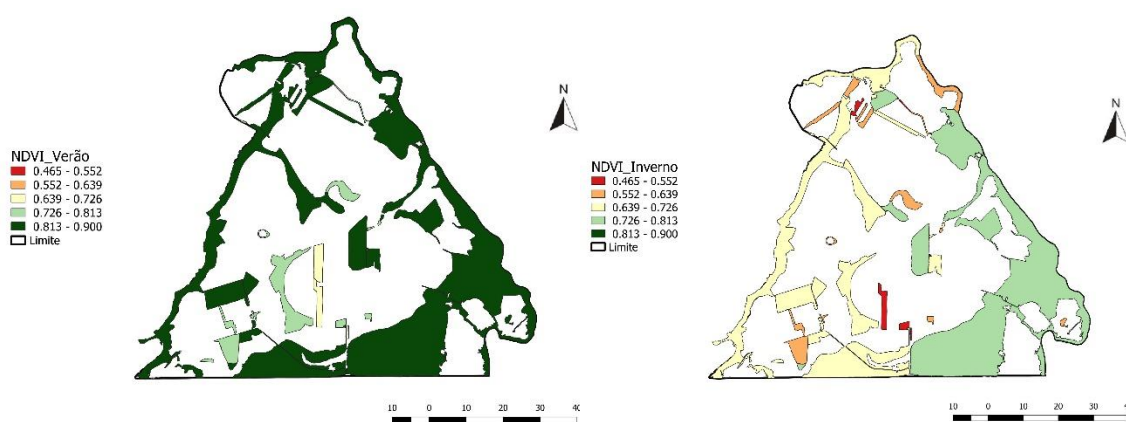


Figura 3 - Distribuição espacial do NDVI da Guarnição da Aeronáutica de Pirassununga (SP) no ano de 2018, período do verão e inverno respectivamente. Fonte: Fernandes, 2018.

Embora a afirmação careça de estudos conclusivos, os mapas de NDVI para as estações de verão e inverno de 2023 em Pirassununga sugerem uma relação com as condições climáticas locais. No verão, particularmente no mês de abril, marcado por altas temperaturas e ocorrência de chuvas, as áreas de Cerradão e trechos da Floresta Estacional Semidecidual (FES) apresentaram NDVI moderado (Figura 4). Esse comportamento pode ser atribuído à maior evapotranspiração, influenciada tanto pela disponibilidade hídrica quanto pela alta demanda atmosférica, característica do período.

A estrutura dessas vegetações contribui para esse padrão. O Cerradão, com sua composição mais densa e rica em fitomassa em comparação ao Cerrado típico, responde melhor à disponibilidade hídrica, mantendo atividade fotossintética mesmo em períodos de transição climática. De forma semelhante, a FES, devido à sua maior

complexidade estrutural e densidade, reflete níveis moderados de NDVI, destacando a presença de espécies adaptadas às condições sazonais.

No inverno, especialmente em setembro de 2023 (Figura 4), o mês foi atipicamente mais chuvoso e úmido. Essa condição climática favoreceu o aumento da biomassa foliar em certas áreas, refletindo NDVI moderados a altos, mesmo em um período em que geralmente se observa a perda parcial de folhas. A plasticidade ecológica das espécies presentes no Cerradão e na FES permite essa resposta adaptativa, mantendo níveis de fotossíntese mais elevados em função das condições climáticas favoráveis.

Essas observações reforçam a necessidade de estudos que aprofundem a correlação entre padrões climáticos, características estruturais das vegetações e os índices de NDVI, especialmente em cenários de variação sazonal e mudanças climáticas.

Para aprofundar esse estudo, será realizada uma análise da série histórica de dados dos anos de 2016 a 2023, com o objetivo de acompanhar a dinâmica da área ao longo do tempo. Essa abordagem permitirá observar as variações nos padrões de vegetação e NDVI, considerando as influências climáticas e sazonais ao longo dos anos. Além disso, a série histórica possibilitará uma compreensão mais detalhada das mudanças nas características das formações vegetais, auxiliando na identificação de tendências e no monitoramento da resposta das diferentes fisionomias vegetais às variações ambientais e às práticas de manejo.

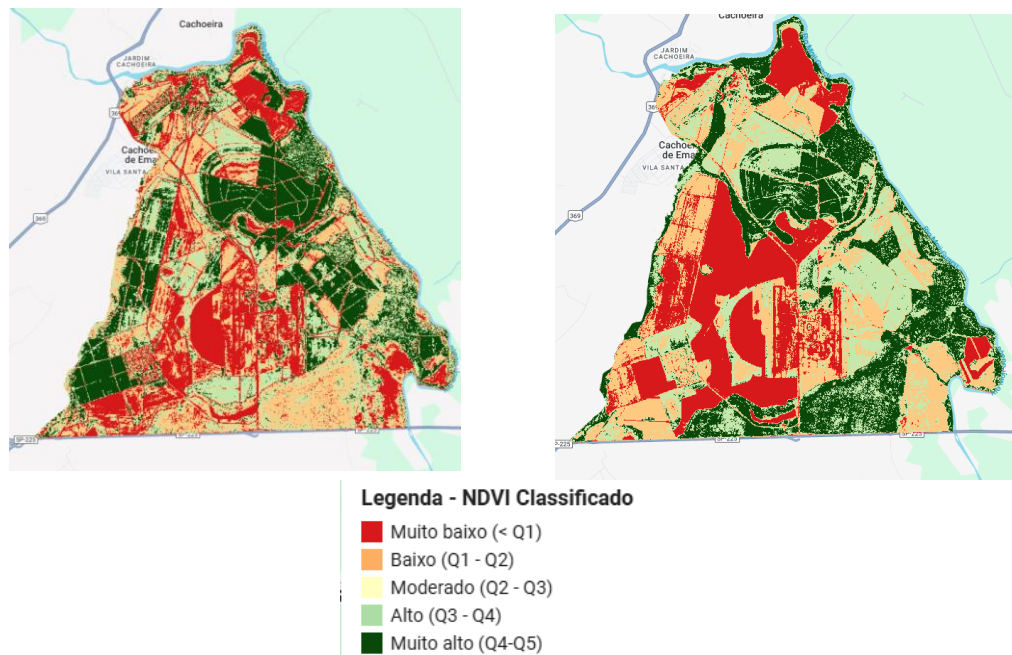


Figura 3 - Distribuição espacial do NDVI da Guarani da Aeronáutica de Pirassununga (SP) no ano de 2023, período do verão e inverno respectivamente. Fonte: As autoras.

6. CÓDIGO FONTE

A seguir, é apresentado o código-fonte do Google Earth Engine (GEE) utilizado para gerar os mapas classificados do NDVI, conforme ilustrado na Figura 4. Este código permite a obtenção dos índices de vegetação normalizados para diferentes períodos, possibilitando a análise temporal e espacial das áreas de interesse.

6.1. Carregando imagens raster do QGI no Google Engine

Para fazer o upload das imagens exportadas no QGIS para o Google Earth Engine, realizamos as seguintes etapas:

1. **Acessamos o Google Earth Engine:** No site [Google Earth Engine](https://earthengine.google.com/) no navegador e fizemos login com uma conta Google.
2. **Acessamos a seção "Assets":** No painel à esquerda, clicamos em "Assets" para gerenciar as imagens carregadas.

3. **Inicie o upload:** Clicamos no botão "New" no canto superior esquerdo, na opção Image Upload, escolhemos " GeoTIFF ".
4. **Selecione as imagens:** Clicamos em "Select" e escolha as imagens GeoTIFF exportadas do QGIS que desejávamos carregar.
5. **Aguarde o upload:** Após selecionarmos os arquivos, clicamos em "Upload". O processo de upload pode levar algum tempo, dependendo do tamanho dos arquivos.
6. **Verificação o status:** Após o upload, você poderá visualizar as imagens na seção "Assets" e verificar se o processo foi concluído com sucesso.

Agora, as imagens raster estarão disponíveis no seu ambiente do Google Earth Engine, prontas para serem processadas e analisadas.

6.2. Criando um Novo Script

1. Dentro do ambiente do Google Engine, na aba “Scripts”, clicamos em "New" no canto superior esquerdo da tela. Escolhemos a opção “File”, isso cria um arquivo de script em branco.
2. Renomeamos o script recém-criado chamado de "Untitled" (sem título) por padrão para Verão e Inverno. Pressionamos Enter para salvar.

6.3. Escrevendo o Código

Dentro da área de edição do script escrevemos os códigos descritos nos itens 6.3.1 e 6.3.2.

6.3.1. Script – Verão

```
// Carregar a imagem do asset (Verão)
var imagemVerao=ee.Image('projects/ee-emmanuellymaria/assets/Verao_2023');

// Função para calcular NDVI
function calcularNDVI(image) {
  return image.normalizedDifference(['b1', 'b2']).rename('NDVI'); // b1= B8
  (NIR), b2= B4 (Red)
}
```

```

// Calcular NDVI
var ndviVerao = calcularNDVI(imagemVerao);

// Definir um CRS e uma área de exportação (ROI)
var crs = 'EPSG:32723'; // Sistema de coordenadas WGS84
var roi = imagemVerao.geometry().bounds(); // Usa o limite da imagem

// Exportar o NDVI para o Google Drive
Export.image.toDrive({
  image: ndviVerao.reproject({crs: crs, scale: 10}),
  description: 'NDVI_Verao_2023',
  folder: 'GEE_Exports',
  fileNamePrefix: 'NDVI_Verao_2023',
  scale: 10, // Resolução da exportação
  region: roi, // Região de exportação
  maxPixels: 1e13
});

```

6.3.2. Script – Inverno

```

// Carregar a imagem NDVI
Var imagemInverno=ee.Image('projects/ee-
emmanuellymaria/assets/Inverno_2023');

// Carregar o shapefile como região de interesse (ROI)
var      roiShapefile      =      ee.FeatureCollection('projects/ee-
emmanuellymaria/assets/shpAFA');

// Função para calcular NDVI
function calcularNDVI(image) {
  return image.normalizedDifference(['b1', 'b2']).rename('NDVI'); // Bandas do
NDVI: B8 (NIR), B4 (Red)
}

```

```

// Calcular o NDVI da imagem
var ndviInverno = calcularNDVI(imagemInverno);

// Calcular os percentis usando o shapefile como ROI
var percentiles = ndviInverno.reduceRegion({
  reducer: ee.Reducer.percentile([25, 50, 75]),
  geometry: roiShapefile.geometry(),
  scale: 10, // A escala é ajustada conforme necessário
  maxPixels: 1e13
});

// Obter os valores dos percentis
var q25 = ee.Number(percentiles.get('NDVI_p25'));
var q50 = ee.Number(percentiles.get('NDVI_p50'));
var q75 = ee.Number(percentiles.get('NDVI_p75'));

// Criar imagens a partir dos quartis
var q25Image = ee.Image(q25).rename('q25');
var q50Image = ee.Image(q50).rename('q50');
var q75Image = ee.Image(q75).rename('q75');

// Classificar o NDVI em quartis utilizando .where()
var ndviClassificadoInverno = ndviInverno
  .where(ndviInverno.lt(q25Image), 0) // Muito baixo
  .where(ndviInverno.gte(q25Image).and(ndviInverno.lt(q50Image)), 1) // Baixo
  .where(ndviInverno.gte(q50Image).and(ndviInverno.lt(q75Image)), 2) // Moderado
  .where(ndviInverno.gte(q75Image), 3); // Alto

// Aplicar paleta de cores
var palette = ['#d7191c', '#fdae61', '#ffffbf', '#abdda4', '#0a480a'];
var ndviVizParams = {
  min: 0,

```

```

max: 3, // Número de classes (0 a 3)
palette: palette
};

// Função para criar a legenda
function criarLegenda(paleta, rótulos) {
  var legenda = ui.Panel({
    style: {
      position: 'bottom-left',
      padding: '8px 15px'
    }
  });

  // Título da legenda
  var título = ui.Label({
    value: 'Legenda - NDVI Classificado',
    style: { fontWeight: 'bold', fontSize: '16px', margin: '0 0 8px 0', padding: '0' }
  });
  legenda.add(título);

  // Adicionar cada cor e rótulo
  for (var i = 0; i < paleta.length; i++) {
    var cor = ui.Label({
      style: {
        backgroundColor: paleta[i],
        padding: '8px',
        margin: '0 0 4px 0'
      }
    });

    var texto = ui.Label({
      value: rótulos[i],
      style: { margin: '0 0 4px 6px' }
    });
  }
}

```

```

    var linha = ui.Panel({
        widgets: [cor, texto],
        layout: ui.Panel.Layout.Flow('horizontal')
    });
    legenda.add(linha);
}

return legenda;
}

// Rótulos correspondentes às classes
var labels = [
    'Muito baixo (< Q1)',
    'Baixo (Q1 - Q2)',
    'Moderado (Q2 - Q3)',
    'Alto (Q3 - Q4)',
    'Muito alto (Q4-Q5)'
];

// Recortar o NDVI classificado para o ROI
var ndviClassificadoClipInverno = ndviClassificadoInverno.clip(roiShapefile);

// Adicionar a camada recortada ao mapa
Map.addLayer(ndviClassificadoClipInverno, ndviVizParams, 'NDVI
Classificado Inverno (Recortado)');

// Criar a legenda e adicioná-la ao painel da UI
var legenda = criarLegenda(palette, labels);
Map.add(legenda);

// Exportar a imagem classificada para o Google Drive
Export.image.toDrive({
    image: ndviClassificadoClipInverno.reproject({crs: 'EPSG:32723', scale: 10}),
    description: 'NDVI_Classificado_Inverno_2023',

```

```
folder: 'GEE_Exports', //Nome da pasta no Google Drive
fileNamePrefix: 'NDVI_Classificado_Inverno_2023',
scale: 10, // Resolução (em metros) da imagem exportada
region: roiShapefile.geometry(), // Região de interesse (ROI) baseada no
shapefile
maxPixels: 1e13 //Limite máximo de pixels para exportação
});
```